[과제] CNN 전이학습(Transfer Learning) 수행과제

변재근

[단계1] 데이터셋 선정 및 다운로드 (Dataset Preparation)

Q1-1. 사용할 데이터셋의 이름, 출처(링크 등), 그리고 데이터셋을 선정한 이유를 설명하시오.

- 데이터셋의 이름 : Car Images Dataset
- 출처 : https://www.kaggle.com/datasets/kshitij192/cars-image-dataset
- 선정이유 : 개인적으로, 내년에 도로 주행 중 음주운전 의심 차량을 발견했을 때 바로 신고할 수 있는 [음주운전 방지 및 신고 앱]을 제작할 계획이기 때문에, 일단 시작점으로서 기본적인 딥러닝 사진 학습을 통해 차량 관련 정보를 정확히 맞추는 기본기능으로 확장될 가능성이 있다고 생각하여 자동차 이미지 분류를 주제로 선정하였다.

Q1-2. 데이터셋의 총 이미지 수, 클래스(Class) 개수, 각 클래스별 데이터 분포(균등,편향)를 요약하시오.

- 총 이미지 수 : 4,165 (Train: 3,352 / Test: 813)
- 클래스 수 : 7 (자동차 브랜드명)
- 클래스별 데이터 분포 : **전체 데이터는 클래스별 분포가 불균등**하여 Audi 등 일부 클래스의 비중이 높으며, Train 데이터를 8:2로 분리해 학습·검증하였고 별도 Test 데이터로 평가하되 클래스 불균형을 고려해 성능을 분석하였다.

클래스명	Train 폴더	Test 폴더	합계	전체 중 비율
Audi	814	199	1,013	24.32 %
Hyundai Creta	271	67	338	8.12 %
Mahindra Scorpio	316	75	391	9.39 %
Rolls Royce	311	74	385	9.24 %
Swift	424	102	526	12.63 %
Tata Safari	441	106	547	13.13 %
Toyota Innova	775	190	965	23.17 %
합 계	**3,352**	**813**	**4,165**	**100 %**

[단계2] 사전 학습 모델(Pre-trained Model) 탐색 및 선정 (Model Exploration)

Q2-1. 컴퓨터 비전 분야에서 널리 쓰이는 사전 학습 모델 3가지 이상을 조사하고 각각의 특징(구조, 장점 등)을 비교하시오. (예: ResNet, VGG, EfficientNet, MobileNet 등)

① **ResNet**

- **구조:** 잔차 연결(Residual/Skip Connection)을 이용하는 CNN 구조이다.
  ResNet18, ResNet50, ResNet152 등 여러 깊이의 모델이 있다.
- **특징:** 수업에서 ResNet152를 이용한 전이학습 및 모델 불러오기를 학습했으므로 기존 수업내용 복습 및 활용이 용이하고, 깊은 신경망에서 학습이 원활하게 이루어지는 무난한 모델이다.

② **VGG**

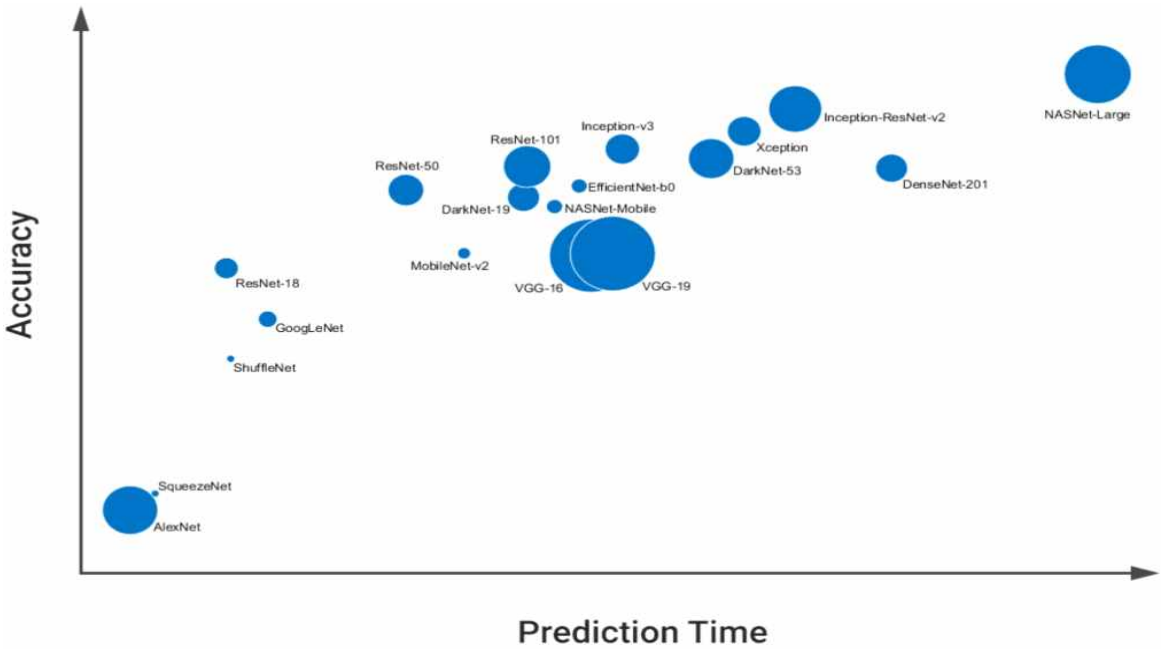
- **구조:** 3×3 합성곱 층을 여러 개 쌓는 비교적 직관적인 구조이다.
- **특징:** 구조가 이해하기 쉽지만, 모델에 따라 파라미터 수와 메모리 사용량이 큰 편이다.

③ **MobileNet**

- **구조:** Depthwise Separable Convolution 등 연산량을 줄이는 구조를 사용한다.
- **특징:** 모바일 기기나 연산 자원이 제한된 환경에서 활용하기 적합한 경량 모델 계열이다.

④ **EfficientNet**

- **구조:** 네트워크의 깊이, 너비, 입력 이미지 해상도를 균형 있게 조정하는 방식으로 설계되었다.
- **특징:** 모델 크기와 성능의 균형을 고려할 수 있으며 여러 규모의 모델이 제공된다.



Q2-2. 본 과제의 데이터셋에 가장 적합하다고 판단한 사전 학습 모델을 최종 선정하고, 그 이유를 서술하시오.

- 선정: **ResNet50**
- 이유: **정확도**와 **수행시간**을 고려했을 때, **밸런스**가 있는 모델들 중에서 꽤 **가벼운** 편에 속한다고 생각해서 선정하였다.

[단계3] 데이터셋 크기와 유사도에 따른 미세조정(Fine-Tuning) 전략 수립 (Strategy & Implementation)

Q3-1. 현재 본인의 데이터셋은 위 4가지 상황 중 어디에 해당하는지 분석하고, 결정한 미세조정 방식 (전체 동결, 일부 동결 후 미세조정, 전체 재학습 등)을 간단히 기술하시오.

- 본 데이터셋은 학습 이미지가 2,682장으로 비교적 적고, 자동차 사진이 ImageNet의 자연 이미지와 유사하므로, **'데이터가 적고 사전학습 데이터와 유사도가 높은 상황'**에 해당한다고 판단하였다.
  따라서, ResNet50의 **기존 특징 추출층**을 **전체 동결**하고, **마지막 FC층만 7개 클래스 분류용으로 교체하여 학습**하였다.
  이 방식은 전체 재학습이나 일부 동결 후 미세조정(Fine-Tuning)보다 학습 부담이 적어 CPU 환경에는 적합하지만, 자동차의 세부 특징을 학습하는 데 한계가 있을 수 있다.

Q3-2. 선택한 전략에 맞춰 PyTorch 또는 TensorFlow/Keras 코드를 작성하고, 모델의 학습(Training) 과정을 수행하시오. (코드 및 학습 로그 첨부)

- PyTorch와 torchvision을 활용하여 ImageFolder로 자동차 데이터를 불러왔음
- 이미지 크기 조정 및 정규화를 적용
- Train 2,682장, Validation 670장, Test 813장으로 구성하고, 배치 크기는 16으로 설정
- ImageNet 사전학습 모델인 ResNet50의 기존 가중치를 동결하고 FC층만 학습하였다.
- 손실함수는 CrossEntropyLoss, 최적화 함수는 Adam, 학습률은 0.001로 설정
- 구글 코랩의 GPU 대여불가 이슈로 인해, CPU 환경에서 총 3 Epoch 학습
- 사전학습된 ResNet50의 기존 가중치를 동결하고, 역전파와 Adam 최적화 함수를 이용하여 마지막 FC층만 학습 (전이학습 中 특징 추출 방식)
- 검증 시에는 torch.no_grad()를 적용
- **코드는 함께 첨부된 .ipynb 파일 참조**

[학습 로그]

Epoch 1/3 | Train Loss: 1.2702 | Train Accuracy: 60.89% | Val Loss: 0.9394 | Val Accuracy: 71.79%
Epoch 2/3 | Train Loss: 0.7497 | Train Accuracy: 80.91% | Val Loss: 0.7044 | Val Accuracy: 81.19%
Epoch 3/3 | Train Loss: 0.5636 | Train Accuracy: 87.25% | Val Loss: 0.5984 | Val Accuracy: 84.48%

[단계4] 결과 평가 및 고찰 (Evaluation & Conclusion)

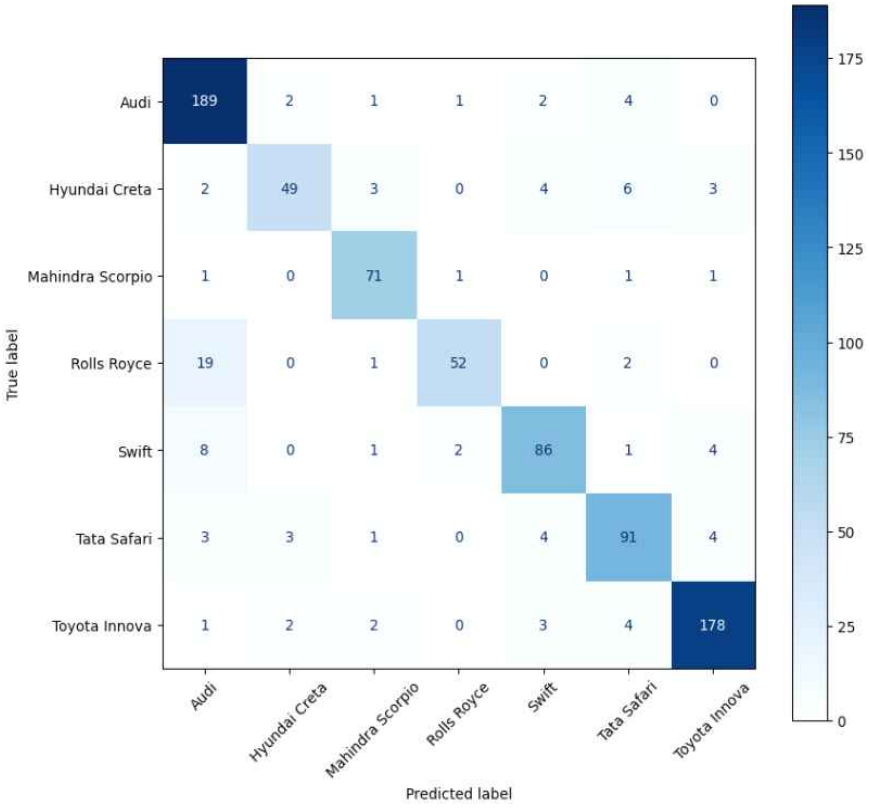
Q4-1. Test 데이터셋에 대한 최종 모델의 성능 지표(Accuracy, Precision, Recall, F1-Score 등)를 제시하고 혼동 행렬(Confusion Matrix)을 분석하시오.

	Precision	Recall	F1-Score	Support
Audi	0.8475	0.9497	0.8957	199
Hyundai Creta	0.8750	0.7313	0.7967	67
Mahindra Scorpio	0.8875	0.9467	0.9161	75
Rolls Royce	0.9286	0.7027	0.8000	74
Swift	0.8687	0.8431	0.8557	102
Tata Safari	0.8349	0.8585	0.8465	106
Toyota Innova	0.9368	0.9368	0.9368	190

accuracy			0.8807	813
macro avg	0.8827	0.8527	0.8640	813
weighted avg	0.8827	0.8807	0.8789	813

[혼동행렬]

```
[[189   2   1   1   2   4   0]
 [  2  49   3   0   4   6   3]
 [  1   0  71   1   0   1   1]
 [ 19   0   1  52   0   2   0]
 [  8   0   1   2  86   1   4]
 [  3   3   1   0   4  91   4]
 [  1   2   2   0   3   4 178]]
```



- 전체 Test 이미지 813장 중 716장을 정확히 분류하여 **정확도 88.07%**를 기록하였다.
  특히 **Audi(189/199장)**와 **Toyota Innova(178/190장)**의 **분류 성능이 높았다.**
  반면 **Rolls Royce**는 74장 중 19장을 Audi로 잘못 분류하여 **가장 큰 혼동**을 보였다.
  이를 통해 **클래스별 분류 성능에 차이가 있음을 확인**하였다.

Q4-2. 학습 과정에서 발생한 문제점(예: 과적합, 학습 지연 등)과 이를 해결하기 위해 시도한 방법 (Learning Rate 조절, Dropout, Augmentation 등)을 작성하시오.

① 학습 과정에서 발견한 문제점

전체 Test **정확도**는 88.07%로 **양호**했지만, **클래스별 성능 차이**가 있었다.

특히 Rolls Royce의 재현율(Recall)은 70.27%, Hyundai Creta는 73.13%로 낮았으며, Rolls Royce 19장을 Audi로 잘못 분류하였다.

이는 클래스별 데이터 수의 불균형이나 차량의 시각적 특징 등이 영향을 미쳤을 가능성이 있으나, 정확한 원인은 추가 분석이 필요하다.

② 실제 적용한 학습 방법

데이터 규모와 CPU 환경의 연산 부담을 고려하여 ImageNet으로 사전학습된 **ResNet50**의 **특징 추출 층을 동결하고, 마지막 FC층만 학습**하는 **전이학습 방식**을 적용하였다.

이를 통해 학습 대상 파라미터를 14,343개로 줄였다.

최적화 함수는 Adam, 학습률(Learning Rate)은 0.001로 설정하고 총 3 Epoch 학습하였다.

③ 학습 결과 및 과적합 여부

Train 정확도는 60.89%에서 87.25%로, Validation 정확도는 71.79%에서 84.48%로 향상되었으며, 두 데이터의 손실값도 지속적으로 감소하였다.

따라서 **뚜렷한 과적합(Overfitting) 현상은 관찰되지 않았다.**

다만 학습 횟수가 3 Epoch로 적어 장기적인 과적합 여부까지 판단하기는 어렵다.

GPU 사용이 불가능하여 CPU로 학습했지만, 학습 시간은 별도로 측정하지 않았다.

④ 한계 및 향후 개선 방안

이번 실험에서는 학습률 변경, Dropout 추가, 데이터 증강(Augmentation) 등의 **비교 실험**은 수행하지 못하였다.

향후에는 오분류된 이미지를 분석하고, 데이터 증강과 클래스 불균형 보정, 학습률 조절 및 일부 층의 미세조정(Fine-Tuning)을 적용하여 성능 변화를 비교해 보고자 한다.

특히, 재현율이 낮은 클래스의 분류 성능 개선을 중점적으로 확인할 계획이다.